O que iremos aprender

Na aula de hoje iremos explorar como realizar validações com great expectations em um projeto com esquema de arquivos

A ideia é explorarmos um cenário mais próximo do produtivo, ao invés de utilizarmos o jupyter notebook.

Hands on

Instalando o Great expectations

Bora lá então galera, o primeiro passo é se certificar que o Great Expectations está instalado em seu ambiente Python. Você pode fazer isso executando os seguintes comandos no seu terminal:

pip install great_expectations great_expectations --version

Inicializando o projeto

Após executar esse comando, você pode executar o comando para inicializar um projeto do great expectations:

great_expectations init

```
- Alsays know what to expect from your data ~

Let's create a new Data Context to hold your project configuration.

Great Expectations will create a new directory with the following structure:

great expectations | -- great expectations.yml |
-- great expectations |
-- proved expectations |
-- proved expectations |
-- plugins |
-- gittigrore |
-- uncommitted |
-- config variables.yml |
-- data docs |
-- validations |

OK to proceed? [Y/n]: Y

Congratulations! You are now ready to customize your Great Expectations configuration.

You can customize your configuration in many ways. Here are some examples:

Use the CLI to:
-- Run 'great' expectations datasource new' to connect to your data.
-- Run 'great' expectations suffer -help' to create, edit, list, profile Expectation Suite(s) in a Checkpoint for later re-validation.
-- Run 'great' expectations suffer -help' to create, edit, list, profile Expectation Suites.
-- Run 'great expectations docs --help' to build and manage Data Docs sites.

Edit your configuration in great expectations.yml to:
-- Yove Stores to the cloud
-- Add Slack notifications, PagerOuty alerts, etc.
-- Customize your Data Docs

Please see our documentation for more configuration options!
```

A estrutura do projeto

great_expectations

|-- great_expectations.yml # Este é um arquivo YAML que contém a configuração principal do projeto Great Expectations. Ele geralmente inclui informações como conexões de banco de dados, configurações de armazenamento e outras configurações de projeto.

|-- expectations # Este é um diretório onde você pode armazenar os arquivos de especificações de expectativas. As expectativas são as regras ou condições que seus dados devem atender.

- |-- checkpoints # Este diretório pode conter checkpoints, que são conjuntos de expectativas que foram validadas em um determinado momento no tempo. Eles podem ser úteis para rastrear a qualidade dos dados ao longo do tempo.
- |-- plugins # Este diretório pode conter plugins adicionais para o Great Expectations. Os plugins podem adicionar funcionalidades extras, como suporte a diferentes tipos de fontes de dados ou integrações com outras ferramentas.
- |-- .gitignore # Este é um arquivo que especifica quais arquivos e diretórios devem ser ignorados pelo Git, um sistema de controle de versão. Isso geralmente inclui arquivos temporários, arquivos de compilação e outros arquivos que não devem ser versionados.
- |-- uncommitted # Este é um diretório onde você pode colocar arquivos que ainda não foram confirmados no controle de versão. Isso pode incluir arquivos de configuração, documentação ou resultados de validação que ainda não foram revisados ou aprovados para inclusão no repositório principal
- |-- config_variables.yml # Este arquivo YAML pode conter variáveis de configuração específicas do ambiente ou do projeto. Por exemplo, você pode definir variáveis de ambiente ou configurações de conexão de banco de dados aqui.
- |-- data_docs # Este diretório pode conter documentação gerada automaticamente sobre os dados, incluindo estatísticas, perfis de colunas e outras informações úteis para entender o conjunto de dados
- |-- validations # Este diretório pode conter resultados de validações anteriores, como logs ou relatórios de validação, que podem ser úteis para rastrear a qualidade dos dados ao longo do tempo.

A base que iremos extrair Configurando o projeto

Agora que criamos o projeto podemos alterar o arquivo yaml great_expectations na raiz do projeto, adicionando o json a seguir para configurar o autos_cleansed.csv como um datasource

Execute: great_expectations datasource new Escolha a opção 1 pandas

```
As of V0.16, the preferred method for adding a Datasource is using the fluent method of c onfiguration, and not using the CLI.

You can read more about this here: https://greatexpectations.io/blog/the-fluent-way-to-co nnect-to-data-sources-in-gx

If you would like to proceed anyway, press Y. [Y/n]: Y

What data would you like Great Expectations to connect to?

1. Files on a filesystem (for processing with Pandas or Spark)

2. Relational database (SQL)

1. What are you processing your files with?

1. Pandas


2. PySpark

1. 1
```

Depois passe o caminho do .csv absoluto até a pasta onde estará o arquivo

Enter the path of the root directory where the data files are stored. If files are on loc al disk enter a path relative to your current working directory or an absolute path. : C:\Users\costa\workspace\ada-tech\engenharia-de-dados-cursos\analytics-engineering\aula 5\dados

Execute o jupyter notebook que o great expectations abrir, que o arquivo yml vai ser automaticamente modificado



A célula do yml é a mais importante pois será a que realizará a configuração no yml principal do great expectations de um novo data source

É possível também testar esse yml no contexto do framework

E a última célula executável realiza um commit da modificação no yml

```
## Save Your Datasource Configuration ## Here we will save your Datasource in your Data Context once you are satisfied with the configuration. Note that overwrite_existing_defaults to False, but you may change it to True if you wish to overwrite. Please note that if you wish to include comments you must add them directly to your <code>great_expectations.yml</code>.

## Sanitize_yaml_and_save_datasource(context, example_yaml, overwrite_existing=False)

## Context.list_datasourcess()

## MARNING* A Datasource named "my_datasource" already exists in this Data Context. The Datasource has *not* been saved. Please use a different name or set overwrite.existing=True if you want to overwrite!

## Context.list_datasource*

## Oataso_name*: "great_expectations.datasource."

## Oataso_name*: "great_expectations.datasource.

## oadule_name*: "great_expectations.datasource.

## oadule_name*: "great_expectations.datasource.

## oata_connectors*: ("default_inferred_data_connector_name*: ("class_name*: "InferredAssetFilesystemDataConnector',

## oastets*: ("my_nuntime_data_connector_name*: ("class_name*: "KuntimeDataConnector',

## oastets*: ("my_nuntime_data_connector_name*: ("class_name*: "KuntimeDataConnector',

## oastets*: ("my_nuntime_data_connector_name*: ("class_name*: "Asset",

## oastets*: ("my_nuntime_data_con
```


O yml estará alterado conforme previsto

```
la_3 > gx > ! great_expectations.yml
    # config version refers to the syntactic version of this config file, and is use
    # It is auto-generated and usually does not need to be changed.
    config version: 3.0
    # Read more at https://docs.greatexpectations.io/docs/guides/connecting_to_your_
    datasources:
      my datasource:
        class name: Datasource
        module_name: great_expectations.datasource
        execution_engine:
          class_name: PandasExecutionEngine
          module name: great expectations.execution engine
        data connectors:
          default inferred data connector name:
            class name: InferredAssetFilesystemDataConnector
            module_name: great_expectations.datasource.data_connector
            base_directory: ..\dados
              group names:
                - data asset name
              pattern: (.*)
          default_runtime_data_connector_name:
            class name: RuntimeDataConnector
            module name: great expectations.datasource.data connector
                 module_name: great_expectations.datasource.data_connector.asset
                 batch identifiers:
                   - runtime_batch_identifier_name
```

Após executar esses comandos o datasource estará criado, e então poderemos criar a nossa suite de testes

Buildando a documentação pela primeira vez

Agora que já definimos o arquivo csv como datasource, vamos configurar as nossas expectations, mas antes disso vamos iniciar o buildar nosso projeto, executando o comando abaixo:



Podemos ver que não existe nenhuma suite de testes, ou execução criada.

Criando as expectativas

Execute o comando

great expectations suite new

PS C:\Users\costa\workspace\ada-tech\engenharia-de-dados-cursos\analytics-engineering\aul
a_3\gx> great_expectations suite new

How would you like to create your Expectation Suite?

1. Manually, without interacting with a sample Batch of data (default)
2. Interactively, with a sample Batch of data
3. Automatically, using a Data Assistant
: 3

Passe o arquivo que você deseja utilizar, no nosso caso o autos_cleaned.csv

A batch of data is required to edit the suite - let's help you to specify it.

Which data asset (accessible by data connector "default_inferred_data_connector_name") wo uld you like to use?

1. .ipynb_checkpoints
2. autos.csv
3. autos_cleaned.csv
4. test.csv


Type [n] to see the next page or [p] for the previous. When you're ready to select an ass et, enter the index.

: 3


E então nomeie a suite de testes

Name the new Expectation Suite [autos_cleaned.csv.warning]: autos

Aperte Y para proceder e então será aberto um novo jupyter, a ideia desse é testar algumas expectations padrão de profilling, como o do y_data_profilling que vimos em aulas anteriores, além disso o arguivo autos.json também foi criado.



Agora podemos executar as células do jupyter que são bem auto explicativa



Essa primeira instancia um validador para criar a suite de fato

A segunda, nós podemos tirar as colunas ou adicionar, que queremos criar testes, eu vou tirar todas

```
Select columns

Select the columns on which you would like to set expectations and those which you would like to ignore.

Great Expectations will choose which expectations might make sense for a column based on the data type and cardinality of the data in each selected column.

Simply comment out columns that are important and should be included. You can select multiple lines and use a Jupyter keyboard shortcut to toggle each line:

Linux/Windows: Ctrl-/, macOs: Cmd-/

Other directives are shown (commented out) as examples of the depth of control possible (see documentation for details).


[ ]:

exclude_column_names = [
    "Unmaned: 0",
    "datecrealed",
    "anse",
    "price",
    "abtest",
    "vehicleType",
    "yearOfRegistration",
    "gearbox",
    "montlofRegistration",
    "fullype",
    "hrand",
    "notRepaireddbasage",
    "dateCreated",
    "notRepaireddbasage",
    "dateCreated",
    "postalcode",
    "lastSeen",
    ]


]
```



Cria a suite com as colunas que queremos, entao ele vai gerar uma serie de expectations para as colunas da tabela



Esse passo pode demorar um pouco



Agora vamos salvar o resultado da nossa suite, ele inclusive cria um checkpoint

Podemos ver que foram executadas mais de 100 expectations

É possível alterar a suite com o comando

Next steps


After you review this initial Expectation Suite in Data Docs you should edit this suite to make finer grained adjustments to the expectations. This can be done by running great_expectations suite edit autos.

Mas também é possivel alterar via yml


Vamos executar o comando

great_expectations docs build


Para avaliarmos a suíte que foi executada




Podemos ver, que o checkpoint foi executado, mas nesse caso não foi criado um yml



Podemos verificar que o gx conseguiu criar 110 expectativas automáticas que tiveram 100% de sucesso para todas as colunas da tabela, isso mostra o poder da ferramenta que permite uma cobertura de testes enorme com pouco esforço de configuração e de forma simples



Agora vamos criar um checkpoint para deixar parametriza e reutilizável, o que utilizamos foi somente em memória via jupyter great_expectations checkpoint new checkpoint_autos
Novamente vamos para uma interface jupyter



E vamos executar novamente as células, que gerarão nosso checkpoint final

Glad you asked! Checkpoints are very versatile. For example, you can validate many Batches in a single Checkpoint, validate Batches against different Expectation Suites or against many Expectation Suites, control the specific post-validation actions based on Expectation Suite / Batch / results of validation among other features. Check out our documentation on Checkpoints for more details and for instructions on how to implement other more advanced features including using the Checkpoint class:

```
[2]: my checkpoint name = "checkpoint_autos" # This was populated from your CLI command
                                                                                                                                                                                                                                                        ⑥↑↓占♀▮
           yaml_config = f"
           name: {my_checkpoint_name}
config_version: 1.0
          print(yaml config)
           name: checkpoint autos
          name: checkpunt autos
config_version: 1.0
class_name: SimpleCheckpoint
run_name_template: "%Y%m%d-%H%M%S-my-run-name-template"
validations:
                 idations:
batch_request:
    datasource_name: my_datasource
    data_connector_name: default_inferred_data_connector_name
    data_asset_name: autos_cleaned.csv
    data_connector_query:
    index: -1
expectation_suite_name: autos
```


É possivel verificar como ficara o checkpoint final

```
Review Your Checkpoint

You can run the following cell to print out the full yaml configuration. For example, if you used SimpleCheckpoint this will show you the default action list.

[6]: print(ay_checkpoint_get_config(mode="yaml"))

name: checkpoint_get_config(mode="yaml"))

name: checkpoint_get_config(mode="yaml"))

name: checkpoint_get_config(mode="yaml"))

template_name: default_one: great_expectations.checkpoint

class_name: great_expectations.checkpoint

class_name: stmpleCheckpoint

run_name_template: "Yakad-SHONS-my-run-name-template"
expectation_suite_name:
batch_request:

class_name: store_validation_result

action:

class_name: store_validation_parametersAction

- name: store_valuation_parametersAction

- name: update_data_docs

action:

class_name: UpdateDataDocsAction

evaluation_parameters: {}

runtime_configuration: {}

validations:

- batch_request:

data_ounce_name: my_datasource

data_connector_name: default_inferred_data_connector_name

data_acst_name: audos_claendc_csv

data_connector_query:

index: 1

expectation_suite_name: autos

profilers: []
ge_cloud_id:

expectation_suite_pame: autos

profilers: []
ge_cloud_id:
expectation_suite_pame: autos
```

E o último comando, realiza o add checkpoint, e materializa o arquivo yml

Como podemos ver, o yml está criado corretamente na pasta checkpoints do projeto

```
name: checkpoint autos
     config version: 1.0
     template name:
     module name: great expectations.checkpoint
     class name: SimpleCheckpoint
     run name template: '%Y%m%d-%H%M%S-my-run-name-template'
     expectation suite name:
     batch request: {}
       - name: store_validation_result
         action:
           class name: StoreValidationResultAction
       - name: store evaluation params
          class name: StoreEvaluationParametersAction
       - name: update_data_docs
         action:
          class_name: UpdateDataDocsAction
     evaluation parameters: {}
     runtime configuration: {}
       - batch_request:
          datasource_name: my_datasource
           data_connector_name: default_inferred_data_connector_name
25
          data_asset_name: autos_cleaned.csv
           data connector query:
             index: -1
         expectation suite name: autos
     profilers: []
     expectation suite ge cloud id:
```

Gerando o relatório uma última vez

Ao gerar o data docs novamente, podemos verificar que uma nova execução foi pontuada pelo great expectations, e agora conseguimos compartilhar esse arquivo yaml de checkpoint e trabalhar a partir dele!

Recapitulação

Na aula de hoje, exploramos o Great Expectations em um cenário mais próximo do ambiente produtivo, utilizando uma estrutura de arquivos para organizar o projeto. Começamos instalando o Great Expectations e inicializando um novo projeto. Em seguida, configuramos o datasource para um arquivo CSV específico e criamos expectativas sobre os dados.

Ao construir as expectativas, utilizamos uma interface Jupyter para testar algumas expectativas padrão de profiling e gerar um conjunto de expectativas para as colunas da tabela. Essas expectativas foram automaticamente executadas e verificadas, mostrando o poder da ferramenta para uma cobertura de testes extensa com pouco esforço de configuração.

Após criar as expectativas, construímos a documentação do projeto, permitindo uma visualização clara das execuções e resultados das validações. Geramos um checkpoint para tornar as execuções reutilizáveis e parametrizadas, o que facilita a validação contínua dos dados.

Em resumo, aprendemos a instalar o Great Expectations, inicializar um projeto, configurar o datasource, criar expectativas, construir a documentação e criar checkpoints para validações contínuas dos dados. Essa abordagem oferece uma maneira poderosa e simples de garantir a qualidade dos dados em um ambiente de análise de dados, facilitando a manutenção da confiabilidade dos dados ao longo do tempo.

Nos vemos na próxima aula!